

Inteligencia Artificial Explicable y Confiable Fundamentada en Modelos Físicos Analíticos

Borrador de Introducción – Propuesta de Investigación
Convocatoria Grupos de Investigación Uniovi 2026–2027

Universidad de Oviedo

June 23, 2026

1 Introducción

La adopción de sistemas de aprendizaje profundo en ámbitos de alta responsabilidad como la sanidad, las finanzas, la infraestructura crítica y la administración pública ha situado la transparencia y la confianza entre los requisitos centrales de estos sistemas, al margen de su rendimiento predictivo [1,2]. La naturaleza opaca de estos modelos dificulta que los operadores puedan validar, auditar y asumir responsabilidad sobre sus decisiones [3,4]. A esta dificultad técnica se añade una dimensión regulatoria: el Reglamento General de Protección de Datos (RGPD) y el Reglamento (UE) 2024/1689 de Inteligencia Artificial establecen obligaciones concretas de explicabilidad y trazabilidad para sistemas clasificados como de alto riesgo [2].

La Inteligencia Artificial Explicable (XAI) aborda esta opacidad mediante métodos que pueden clasificarse según tres criterios: el momento de aplicación (post-hoc sobre modelos ya entrenados, o ante-hoc con interpretabilidad intrínseca), el alcance (local para decisiones individuales, o global para el comportamiento general del modelo) y la dependencia arquitectónica (métodos agnósticos o específicos de una arquitectura) [5,6]. Entre los métodos de referencia se encuentran la Propagación de Relevancia por Capas (LRP) [7], las Explicaciones Locales Interpretables Agnósticas del Modelo (LIME) [8], las Explicaciones Aditivas de Shapley (SHAP) [9], la Localización Visual por Gradientes Ponderados por Clase (Grad-CAM, del inglés *Gradient-weighted Class Activation Mapping*) [10] y los Gradientes Integrados [11]. Trabajos posteriores han cuestionado la fiabilidad de estos métodos: Adebayo et al. mostraron que varios de ellos son independientes de los parámetros del modelo entrenado [12], y Ghorbani et al. demostraron que perturbaciones imperceptibles en la entrada pueden modificar sustancialmente los mapas de saliencias sin alterar la predicción [13].

En paralelo, el Grupo de Expertos de Alto Nivel sobre IA de la Comisión Europea formalizó el concepto de Inteligencia Artificial de Confianza (*Trustworthy AI*) en torno a siete dimensiones: supervisión y control humano, robustez técnica y seguridad, privacidad y gobernanza de datos, transparencia y explicabilidad, diversidad y equidad, bienestar social y medioambiental, y rendición de cuentas [2]. La explicabilidad es transversal a las demás dimensiones, ya que sin ella no es posible verificar el cumplimiento de las restantes [3,14]. La Ley de IA de la UE (Reglamento 2024/1689) concreta estas obligaciones: el Artículo 86 reconoce el derecho individual a recibir una explicación de las decisiones de sistemas de alto riesgo; los Anexos I y III delimitan los ámbitos de aplicación, entre ellos dispositivos médicos, infraestructura crítica, evaluación crediticia, selección de empleo y biometría, con entrada en vigor el 2 de agosto de 2026 [2].

1.1 Limitaciones actuales de XAI

La investigación reciente ha identificado una debilidad de base en los métodos de XAI: el diseño *algorithm-first* [1]. Haufe et al. argumentan que los métodos dominantes, incluidos SHAP y

Grad-CAM, se desarrollaron como algoritmos sin una definición previa del problema que deben resolver ni criterios objetivos de corrección [1]. Como resultado, estos métodos pueden atribuir importancia a variables que están correlacionadas con el objetivo pero que no son causalmente relevantes, generando atribuciones que los operadores interpretan como válidas sin que exista garantía de que lo sean [1, 12].

Un segundo problema es la ausencia de verdad de terreno (*ground-truth*) objetiva para evaluar la corrección de las explicaciones. Haufe et al. señalan que no existe *ground-truth* para el problema de XAI en conjuntos de datos reales, lo que obliga a recurrir a sustitutos como el juicio humano o métricas de fidelidad que no garantizan la corrección de la explicación [1]. Palikhe et al. documentan la misma limitación en el ámbito de los modelos de lenguaje, donde las verdades de terreno explicativas son con frecuencia inaccesibles [6]. Gipiškis y Kurasova proponen las Tarjetas de Evaluación de XAI como mecanismo de estandarización, que exigen declarar el contexto de validez y el riesgo de manipulación de cada métrica [15]. Esta situación guarda paralelismo con la saturación que afecta a los *benchmarks* generales de IA: en el primer semestre de 2026, evaluaciones como MMLU-Pro o GPQA Diamond presentan diferencias entre modelos dentro del margen de ruido estadístico, lo que reduce su utilidad discriminativa [16, 17].

Los modelos de aprendizaje profundo tienden a capturar correlaciones presentes en los datos de entrenamiento que no corresponden a mecanismos causales del fenómeno estudiado [13, 14]. En el análisis de electroencefalografía (EEG), por ejemplo, los clasificadores de crisis epilépticas pueden aprender a correlacionarse con artefactos musculares o de movimiento ocular en lugar de con los patrones de actividad ictal [5]. Los métodos post-hoc actuales no pueden distinguir estas correlaciones espurias de las causalmente válidas sin una referencia externa al dominio: la importancia que SHAP o Grad-CAM asignan a una variable no informa sobre si esa importancia es causalmente justificada o un artefacto del entrenamiento [1, 5].

Desde la perspectiva regulatoria, ninguno de los enfoques actuales de XAI ofrece certificabilidad formal de sus explicaciones. Los Modelos Causales Estructurales (SCM) constituyen una línea de trabajo relevante: Binkyte et al. los proponen como mecanismo para resolver los conflictos entre las dimensiones de IA de Confianza [3, 14]. Sin embargo, los SCM son estructuras aprendidas de datos y pueden heredar sus sesgos, por lo que no garantizan validez fuera de la distribución de entrenamiento [14]. El Artículo 86 y los Anexos I y III de la Ley de IA de la UE exigen trazabilidad documental y evaluación de conformidad que los enfoques estadísticos no pueden satisfacer de forma verificable e independiente de los datos [2]. Qi et al. documentan que solo el 30% de las organizaciones han establecido controles de gobernanza adaptados a sistemas autónomos, lo que refleja en parte la ausencia de mecanismos formales de auditoría [4].

1.2 Uso de modelos físicos analíticos en XAI

Este trabajo parte de la observación de que en numerosos dominios de aplicación existen modelos físicos analíticos bien establecidos: ecuaciones de primer principio, modelos de estado, modelos farmacocinéticos y farmacodinámicos (PK/PD) y modelos dipolares neurofisiológicos, entre otros. Estos modelos codifican relaciones causales del dominio con independencia de los datos de entrenamiento, y su validez no está restringida a una distribución observada [5, 14]. Lyberatos et al. identifican la incorporación de *priors* de dominio, como la adyacencia espacial de electrodos o restricciones espectrales de origen neurofisiológico, como una dirección necesaria para dotar de fundamento las explicaciones en EEG, aunque sin un marco formal que lo generalice [5]. La propuesta de este trabajo es formalizar ese rol: el modelo físico analítico define qué atribuciones son admisibles y permite detectar aquellas que contradigan las relaciones causales del dominio.

Una segunda aportación del uso de modelos físicos es la generación de verdad de terreno mediante simulación. El modelo analítico puede producir escenarios con resultado conocido por construcción a partir de las ecuaciones del dominio, sin depender de datos etiquetados, lo que permite medir la tasa de error del explicador de forma objetiva y reproducible [1, 4]. Los sistemas agénticos emplean un principio similar mediante *world models* para verificar las consecuencias

de acciones antes de ejecutarlas [4], pero este mecanismo no se ha trasladado a la evaluación de explicaciones en sistemas de aprendizaje supervisado. El protocolo de certificación resultante es compatible con los requisitos de trazabilidad documental del Art. 86 y los Anexos I y III de la Ley de IA [2].

Una tercera función es la detección de correlaciones espurias. Si el explicador asigna importancia elevada a una variable que el modelo físico indica como irrelevante para el fenómeno, esa discrepancia señala una posible correlación espuria aprendida durante el entrenamiento. Esta capacidad complementa el paradigma de invarianza causal de Binkyte et al. [3]: mientras los SCM identifican correlaciones espurias por su inestabilidad entre distribuciones, el modelo físico las identifica por contradicción directa con las leyes del dominio, con independencia de los datos [5, 14]. Que la detección no dependa de los datos de entrenamiento es relevante para la certificación formal, ya que evita la circularidad de validar el modelo con los mismos datos con que fue entrenado [2].

Este trabajo propone el marco de **Inteligencia Artificial Explicable y Confiable Fundamentada en Modelos Físicos Analíticos** (PG-XAI, del inglés *Physics-Grounded XAI*), que integra modelos físicos analíticos como referencia externa de fidelidad para explicadores de aprendizaje automático en entornos regulados. El objetivo es desarrollar y evaluar los tres mecanismos descritos en **[CASOS DE APLICACIÓN]**. La Sección 2 revisa el estado del arte en XAI y modelos físicos en los dominios considerados; la Sección 3 formaliza el marco PG-XAI; la Sección 4 describe el diseño experimental; la Sección 5 presenta el plan de trabajo para el periodo 2026–2027.

References

- [1] Stefan Haufe, Rick Wilming, Benedict Clark, Rustam Zhumagambetov, Ahcène Boubekki, Jörg Martin, and Danny Panknin. Explainable AI needs formalization. *arXiv preprint arXiv:2409.14590v5*, 2026.
- [2] European Parliament and Council of the European Union. Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act), 2024. Published in the Official Journal of the European Union on 12 July 2024.
- [3] Ruta Binkyte, Ivaxi Sheth, Zhijing Jin, Mohammad Havaei, Bernhard Schölkopf, and Mario Fritz. Position: Trustworthy AI Suffers from Invariance Conflicts and Causality is the Solution. In *Proceedings of the 43rd International Conference on Machine Learning (ICML)*, volume 306 of *Proceedings of Machine Learning Research (PMLR)*, Seoul, South Korea, 2026. PMLR.
- [4] Jinhu Qi, Muzhi Li, Jiahong Liu, Yuqin Shu, Dianshi Yu, Shicheng Ma, Wenqian Cui, Yiyang Zhao, Yiyi Chen, Ruoxi Jiang, Irwin King, and Zenglin Xu. Towards Trustworthy Agentic AI: A Comprehensive Survey of Safety, Robustness, Privacy, and System Security. *Academia AI and Applications*, 2, 2026. arXiv:2605.23989.
- [5] Vassilis Lyberatos, Georgios Kontos, Nikolaos Spanos, Orfeas Menis Mastromichalakis, Athanasios Voulodimos, and Giorgos Stamou. Explainable Artificial Intelligence (XAI) for EEG Analysis: A Survey on Recent Trends and Advancements. *AI*, 7(3):95, 2026.
- [6] Avash Palikhe, Zichong Wang, Zhipeng Yin, Rui Guo, Qiang Duan, Jie Yang, and Wenbin Zhang. Towards Transparent AI: A Survey on Explainable Language Models. *arXiv preprint arXiv:2509.21631*, 2025.

- [7] Sebastian Bach, Alexander Binder, Grégoire Montavon, Frederick Klauschen, Klaus-Robert Müller, and Wojciech Samek. On Pixel-wise Explanations for Non-Linear Classifier Decisions by Layer-wise Relevance Propagation. *PLOS ONE*, 10(7):e0130140, 2015.
- [8] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. “Why Should I Trust You?”: Explaining the Predictions of Any Classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1135–1144, San Francisco, CA, USA, 2016. ACM.
- [9] Scott M. Lundberg and Su-In Lee. A Unified Approach to Interpreting Model Predictions. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 4765–4774, 2017.
- [10] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 618–626, 2017.
- [11] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. Axiomatic Attribution for Deep Networks. In *Proceedings of the 34th International Conference on Machine Learning (ICML)*, volume 70, pages 3319–3328. JMLR.org, 2017.
- [12] Julius Adebayo, Justin Gilmer, Michael Muelly, Ian Goodfellow, Moritz Hardt, and Been Kim. Sanity Checks for Saliency Maps. In *Advances in Neural Information Processing Systems*, volume 31, pages 9505–9515, 2018.
- [13] Amirata Ghorbani, Abubakar Abid, and James Zou. Interpretation of Neural Networks is Fragile. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 33, pages 3681–3688, 2019.
- [14] Ruta Binkyte, Ivaxi Sheth, Zhijing Jin, Mohammad Havaei, Bernhard Schölkopf, and Mario Fritz. Causality Is Key to Understand and Balance Multiple Goals in Trustworthy ML and Foundation Models. *arXiv preprint arXiv:2502.21123v6*, 2026.
- [15] Rokas Gipiškis and Olga Kurasova. Evaluation Cards for XAI Metrics. *arXiv preprint arXiv:2605.04410v1*, 2026.
- [16] Kili Technology. AI Benchmarks 2026: Top Evaluations and Their Limits. Technical report, Kili Technology, April 2026.
- [17] Stanford Institute for Human-Centered AI (HAI). Technical Performance, 2026.